

Segmentação Interativa de Imagens usando Redes Complexas e Competição e Cooperação entre Partículas

Jefferson Antonio Ribeiro Passerini

Orientador: Prof. Dr. Fabricio Aparecido Breve

Agenda

- Introdução
 - Objetivos e Motivações
- Segmentação de Imagens
- Redes Complexas
- Aprendizado de Máquina
- Modelo de Competição e Cooperação de Partículas
 - Aplicação em segmentação de imagens
- Metodologia Proposta
- Resultados Preliminares
- Considerações Finais

Objetivos e Motivação

Objetivo:

- Aplicar o modelo de Competição e Cooperação entre Partículas a segmentação de imagens;
- Propor melhorias na construção da rede complexa a partir da imagem;
- Não utilizar o vetor de pesos para a atribuição de incremento ou decréscimo de importância às características extraídas dos píxeis da imagem

Objetivos e Motivação

Motivação:

- A segmentação de imagens não é uma tarefa não trivial;
- A aplicação de metodologias de aprendizado de máquina pode auxiliar nesta tarefa;
- O modelo aplicado enquadra-se em um paradigma de aprendizado semi-supervisionado;
- Possui custo computacional baixo em relação a outros métodos baseados em grafos;
- Modelo flexível podendo ser aplicado em diversas situações.

Segmentação de Imagens - Definições

- Processo de identificar e separar estruturas e objetos relevantes ou de interesse em uma imagem;
- Não é uma tarefa trivial
- Interferências (pré-processamento)
- Deve-se levar em consideração fatores de baixo nível (brilho, cor, textura, etc) e de alto nível (como demonstrar compreensão a respeito da imagem trabalhada).

Segmentação de Imagens - Métodos

- Métodos Baseados em Descontinuidade
 - Detecção de Pontos Isolados (Gonzalez e Woods (2010))
 - Detecção de Linhas (Gonzalez e Woods (2010))
 - Detecção de Borda (Gonzalez e Woods (2010), Navon, Miller e Averbuch(2005), Castleman(1996))
- Métodos Baseados em Similaridades
 - Limiarização (Gonzalez e Woods(2010), Skarbek e Koschan (1994), Otsu(1979))
 - Crescimento de Regiões (Dass, Priyanka e Devi(2012), Gonzalez e Woods(2010))
 - Divisão e Conquista (Gonzalez e Woods(2010))
 - Bacias Hidrográficas (*Watersheds*) (Araujo(2010), Gonzalez e Woods(2010), Navon, Miller e Averbuch (2005))

Segmentação de Imagens - Métodos

- Técnicas Baseadas em Grafos
 - Graph Cuts (Boykov e Kolmogorov (2004), Boykov e Jolly (2001))
 - GrabCut (Rother, Kolmogorov e Blake (2004))
- Associações dos Grafos a outras técnicas de segmentação:
 - Técnicas de Superpixels (Felzenszwalb e Huttenlocher (2004), Ren e Malik (2003))
 - Bacias Hidrográficas (*Watersheds*) (Navon, Miller e Averbuch(2005))

Redes Complexas - Definições

- Envolve a representação de dados heterogêneos e não triviais e suas relações;
- Seu estudo geralmente é multidisciplinar;
- São utilizadas em inúmeras aplicações : internet, financeira, etc;
- A base inicial são os estudos de Erdős e Rényi;

Aprendizado de Máquina

- **Aprendizado Supervisionado:**
 - Deduzem um modelo ou uma função a partir de dados de treinamento;
 - Dados de treinamento consistem de pares de exemplos de entradas e saídas desejadas;
 - O objetivo: obter uma função que seja capaz de prever a saída para qualquer entrada válida, após o algoritmo ter sido exposto a um número suficiente de exemplos.

Alpaydin (2014), Zamoner(2013).

- **Aprendizado não supervisionado:**
 - Algoritmos que buscam determinar como os dados estão organizados;
 - O processo acontece apenas guiado pelos dados fornecidos sem conhecimento prévio ou rótulos;
 - O objetivo é observar padrões no espaço de entradas

Silva e Zhao (2016), Alpaydin (2014), Chapelle, Schölkopf e Zien (2006).

Aprendizado Semi-Supervisionado

- Algoritmos que fazem uso tanto de dados rotulados quanto de dados não rotulados para treinamento.
- Objetivo: fornecer rótulos para os dados não rotulados;
- Em muitos casos, o uso de alguns dados rotulados em meio aos dados não rotulados melhora consideravelmente a precisão do aprendizado.

Aprendizado Semi-Supervisionado - Técnicas

- Auto Treinamento (Chapelle, Scholkopf e Zien (2006), Zhu(2005))
- Modelos Generativos (Zhu(2005))
- Agrupar e Rotular (Kremer, Stacey (2002), Demiriz, Bennet e Embrechts (1999))
- Co-Treinamento (Zhou e Li(2007), Zhou e Li(2005), Mitchell(1999), Blum e Mitchel(1997), Mitchell(1997))
- Separação por Baixa Densidade (Barber(2012), Zhu(2005))
- Métodos Baseados em Grafos
 - Propagação de Rótulos (Zhu e Ghahramani (2002))
 - Consistência Global e Local (Zhou et al. (2004))
 - Caminhadas Aleatórias (Szummer e Jaakkola (2002))
- **Competição e Cooperação de Partículas (Breve, 2010)**

Cooperação e Competição de Partículas

- Origem:
 - Quiles M.G. et al (2008) “Particle competition for complex network community detection”, Chaos, vol. 18, nº3, 2008;
- Estendido para paradigma de aprendizado semi-supervisionado;
- Menor custo computacional em relação a outros métodos de aprendizado baseado em grafos
- Abordagem local (apenas o nó de interesse no movimento)
- Pode ser utilizado juntamente com a metodologia de aprendizado ativo.


Cooperação e Competição de Partículas – Segmentação de Imagens

- **BREVE, QUILES e ZHAO (2015).** *Interactive Image Segmentation using Particle and Cooperation. Lecture Notes in Computer Science. Springer International, v.9155, p.203-216, 2015.*
- **BREVE, QUILES e ZHAO (2015).** *Interactive image segmentation of non-contiguous classes using particle competition and cooperation. Lecture Notes in Computer Science, Springer International Publishing, v. 9155, p. 203–216, 2015.*
- **BREVE, F. A (2015).** *Auto feature weight for interactive image segmentation using particle competition and cooperation. In: Proceedings - XI Workshop de Visão Computacional WVC2015. [S.l.]: XI Workshop de Visão Computacional (WVC2015), 2015. p. 164 – 169.*
- **BREVE, F. A (2017).** *Building networks for image segmentation using particle competition and cooperation. In: Computational Science and Its Applications, ICCSA, 2017, v.10404, p.217-231.*

Cooperação e Competição de Partículas – Segmentação de Imagens

- Demonstraram a eficiência do modelo de Competição de Cooperação de Partículas para segmentação de imagens;
- Ficou evidente a dificuldade em determinar o conjunto adequado de características que permitam a correta segmentação da imagem.

Definições (PCC) - 1a. Fase



Características: X, Y, RGB, HSV, Média e DP do RGB e HSV, ExR, ExB, ExG



Pesos das Características = {1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1}



Distância Euclidiana Ponderada

$$D(x, y) = \sqrt{(p(x_1 - y_1))^2 + (p(x_2 - y_2))^2 + \dots + (p(x_n - y_n))^2}$$



Relação entre os nós do grafo

{N₀-N₀, N₀-N₁, N₀-N₂, N₀-N₃, ..., N_n-N_m}



Definição dos N vizinhos próximos e montagem da rede




Configuração inicial das partículas



Definição da matriz de distâncias



Definição da Força das Partículas e Nível de domínio das nós do grafo (0-1)




Definições (PCC) - 2a. Fase - Laço Principal

Faça até que a condição de parada seja satisfeita


Seleciona o movimento da partícula

Guloso

Aleatório



Partícula tenta o domínio sobre o vértice vizinho




Verifica critério de parada

O critério de parada acontece a partir do monitoramento dos domínios dos nós

Se a média dos domínios máximos não sofrer variação a cada n iterações encerra execução ou atingindo o número de iteração máxima


$$y_i = \operatorname{argmax}_l v_i^{\omega_l}(\infty)$$

Encerra execução



Metodologia

- Não alterar o modelo de Competição e Cooperação entre Partículas, trabalhar somente a geração de uma nova rede complexa (1ª Fase).
- Informações de entrada para o modelo



(a) Imagem Original (b) Marcação de píxeis rotulados (c) Polígono de Corte (d) Sobreposição de informações para visualização.

Metodologia

- Realizar a Interpolação da imagem para redução de sua dimensão e realizar sua recomposição após o processo de segmentação.

Tabela 6.1 – Resultados Teste de Algoritmos de Interpolação

Abordagem	Imagem	Px Válidos	Px Cinza	Px Erro	% Erros	Dv Padrão	Dv Tempo	Dv Padrão
Bicubica	86016	154401	954	2194	1,43%	0,10%	752,01	49,49
Bicubica	227092	154401	1398	3539	2,31%	0,28%	798,14	81,3
	326038	154401	1606	4053	2,65%	0,07%	803,31	76,45
	Média	154401	1319	3262	2,13%		784,49	
Bilinear	86016	154401	954	2922	1,90%	0,09%	762,93	61,88
Bilinear	227092	154401	1398	3432	2,24%	0,03%	759,14	62,7
	326038	154401	1606	3860	2,53%	0,02%	816,73	93,15
	Média	154401	1319	3405	2,21%		779,60	
Bicubica	86016	154401	954	2202	1,44%	0,11%	752,26	77,71
Bilinear	227092	154401	1398	3417	2,23%	0,26%	774,47	64,6
	326038	154401	1606	3868	2,51%	0,06%	781,42	75,66
	Média	154401	1319	3162	2,05%		769,38	
Bilinear	86016	154401	954	2249	1,47%	0,10%	743,52	97,63
Bicubica	227092	154401	1398	3429	2,24%	0,23%	778,43	54,82
	326038	154401	1606	3977	2,58%	0,09%	790,61	80,54
	Média	154401	1319	3218	2,08%		770,85	

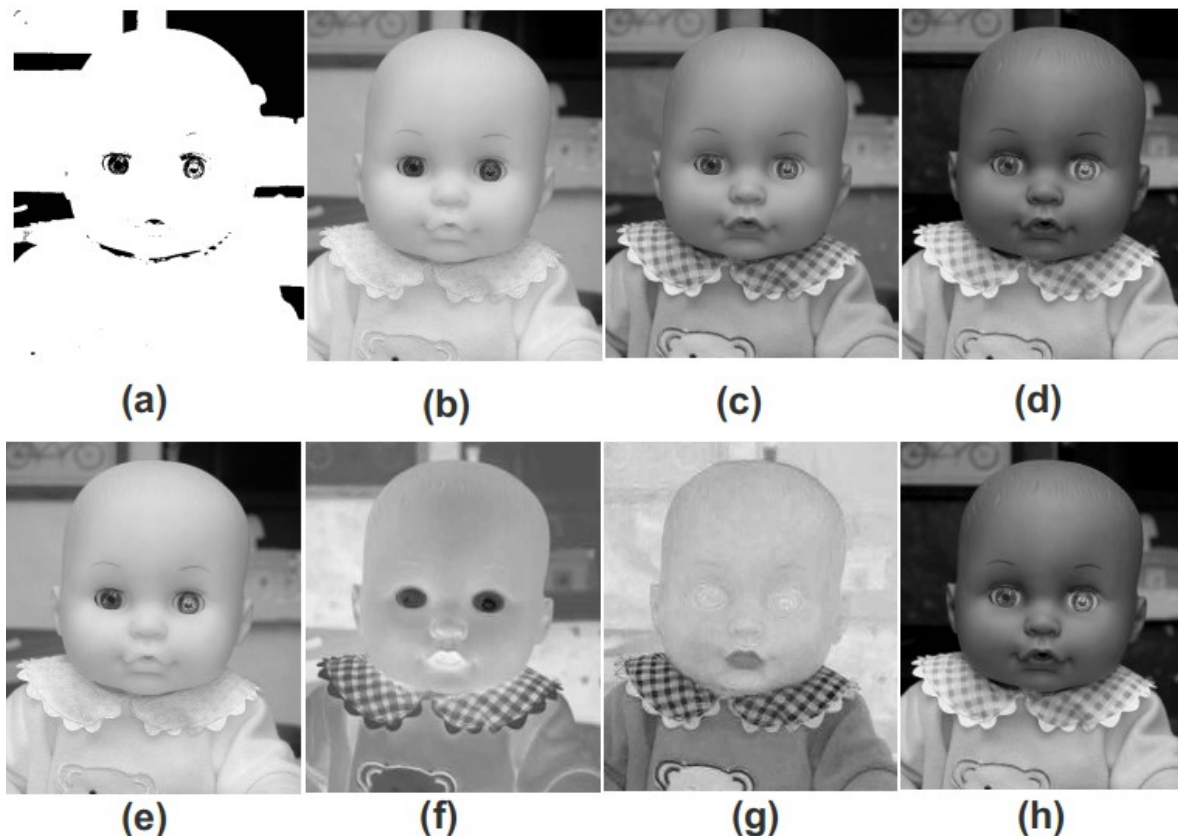
Fonte: Elaborado pelo autor

Configuração dos testes:

- 25 amostras de cada imagem para cada abordagem
- Configurações de execução : $K=200$; $\Delta_v = 0,1$; $P_{grd}=0,5$; $maxIte=1000000$; $maxParada=15000$; $controleParada=0,001$; Vetor de pesos $\lambda = 1$ para todas as características extraídas
- Notebook proc. Intel i7 3537U 2Ghz 4 núcleos e 16GB RAM.

Metodologia

Alteração do conjunto de características extraídas da imagem



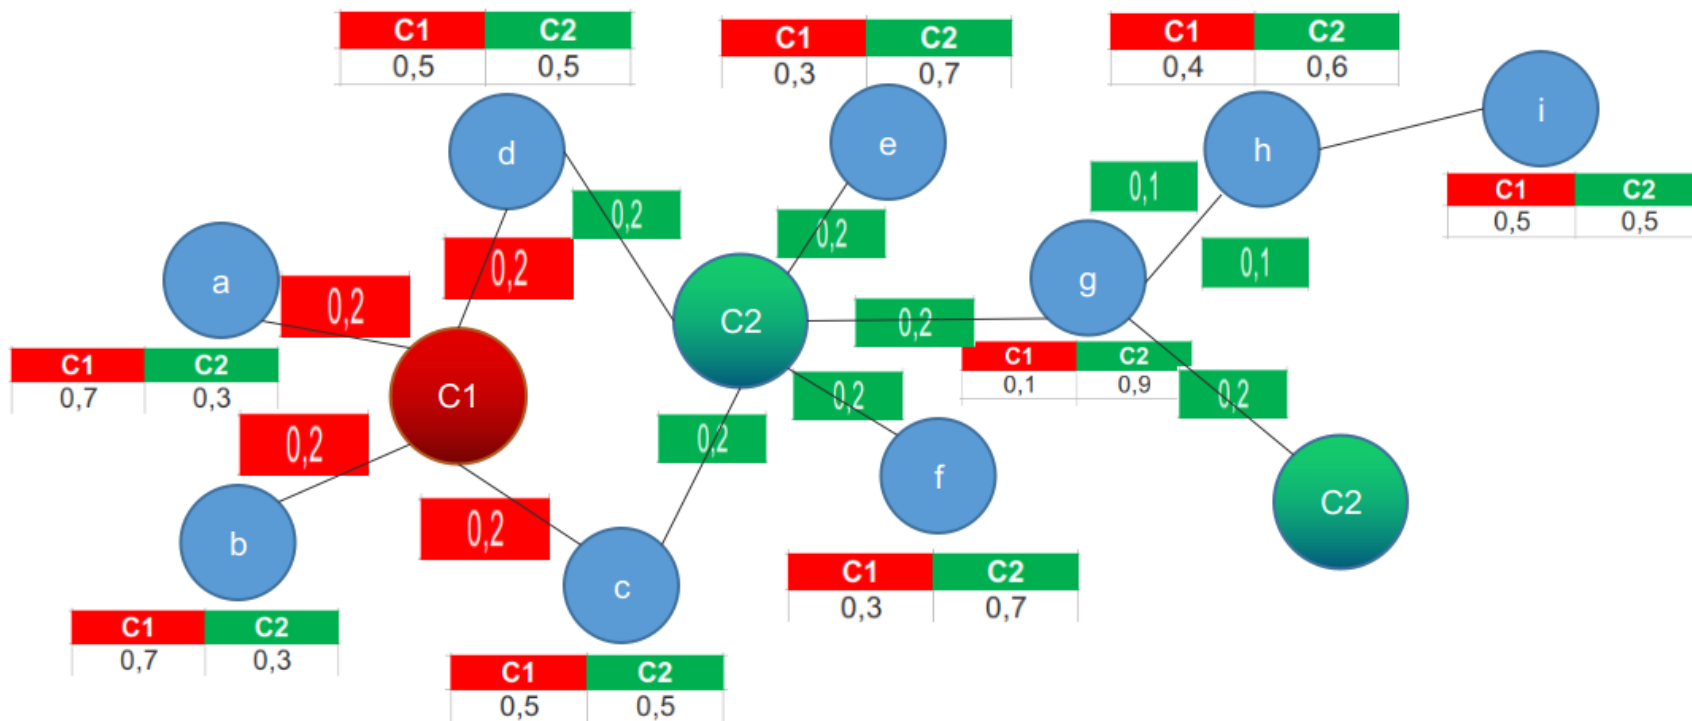
(a) Imagem Binária(Otsu), (b) Componente R do RGB, (c) Componente G do RGB, (d) Componente B do RGB, (e) Intensidade do HSV, (f) ExR, (g) ExG e (h) ExB

Metodologia

- Preparação da rede complexa:
 - $k=200$ (vizinhos próximos):
 - onde 192 vizinhos são determinados por similaridade entre as características através da Distância Euclidiana (sem pesos);
 - e 8 vizinhos são determinados pelos vizinhança espacial do pixel na imagem (8 vizinhos próximos);
 - Alteração visa garantir a representação na rede complexa da situação do pixel e de sua vizinhança como na imagem original;
- Restrição de ligação de vértices, ocorrendo com vértices de mesma classe ou com vértices não rotulados;

Metodologia

- Representa a influência das partículas (píxeis rotulados) em sua vizinhança espacial 5x5 dentro da imagem.




- Vértices gerados a partir de píxeis a distância igual a 1 do pixel analisado sofrem incremento de 0,2 no seu vetor de domínio de classes e vértices com distância igual a 2 sofrem incremento de 0,1.

Experimentos

- Comparação entre os modelos:
 - Modelo Proposto → Metodologia do trabalho;
 - Modelo Testemunha → Algoritmo Original como foi descrito com as 23 características sem ajuste do vetor de pesos;
 - Não houve alterações no modelo de Competição e Cooperação entre Partículas;
- Configuração de execução dos modelos:
 - Vizinhos próximos $k=200$; $\Delta_v = 0,1$; $P_{grd}=0,5$; $maxIte=1.000.000$; $maxParada=15.000$; $controleParada=0,001$; Vetor de pesos $\lambda = 1$ para todas as características extraídas (modelo testemunha);
 - Equipamento: i7 3537U 4 núcleos 2Ghz – 16 GB memória RAM.

Experimentos

- Utilização de 151 imagens (GrabCut);
- Execução de 30 amostras para cada imagem com cada um dos modelos estudados (4530 amostras para cada modelo);
- Taxa de erro determinada através da comparação do resultado da segmentação com a imagem gabarito fornecida com a base.



- (a) Imagem Original (b) Imagem Gabarito (c) Píxeis cinza → divergência classificação

Resultados

Resultado de Imagens onde não foi possível a utilização do recurso do polígono de corte pelo Mod. Proposto

Tabela 7.1 – Características das redes geradas a partir de imagens sem o recurso de Corte

Nome Imagem	Pixel Original	Pixel Cinza	Partículas	Método Proposto		Testemunha	
				Vértices	Arestas	Vértices	Arestas
Baby_2007_006647	187500	7670	6659	16800	1796483	16800	2206608
cross	270000	1870	4206	24300	2883050	24300	3148781
gt02	419200	2229	6294	37680	4371763	37680	4772882
gt07	494400	6656	7598	44400	5247685	44400	5721712
gt13	476000	12429	5314	42720	5149011	42720	5536232
Média	369420	6171	6014	33180	3889598	33180	4277243

Fonte: Elaborado pelo autor

Resultados

Resultado de Imagens onde não foi possível a utilização do recurso do polígono de corte pelo Mod. Proposto

Tabela 7.2 – Taxa de erro dos modelos a partir de imagens sem o recurso de Corte

Nome Imagem	Pixel		Método Proposto			Método Testemunha		
			Px	%	Dv	Px	%	Dv
	Original	Cinza	Erro	Erro	Pad	Erro	Erro	Pad
Baby_2007_006647	187500	7670	2102	1,17%	0,02%	8213	4,57%	0,07%
cross	270000	1870	1276	0,48%	0,03%	4796	1,79%	0,07%
gt02	419200	2229	2180	0,52%	0,02%	5282	1,27%	0,13%
gt07	494400	6656	1005	0,21%	0,03%	3127	0,64%	0,06%
gt13	476000	12429	4995	1,08%	0,06%	9797	2,11%	0,16%
Média	369420	6171	2312	0,64%		6243	1,72%	

Fonte: Elaborado pelo autor

Tabela 7.3 – Tempo de execução dos modelos a partir de imagens sem o recurso de Corte

Nome Imagem	Px Original	Método Proposto		Método Testemunha	
		Tempo(seg)	Desvio	Tempo(seg)	Desvio
Baby_2007_006647	187500	615,65	53,28	1179,81	108,06
cross	270000	1238,05	238,78	1123,14	67,23
gt02	419200	1098,05	38,84	1146,92	68,42
gt07	494400	1567,95	20,95	1637,93	109,4
gt13	476000	1505,62	90,38	1767,62	337,78
Média	369420	1205,06		1371,08	

Fonte: Elaborado pelo autor

Resultados


Resultado de Imagens onde não foi possível a utilização do recurso do polígono de corte pelo Mod. Proposto





Baby_2007_006647 - Proposto - Taxa Erro: 1,17%



Baby_2007_006647 - Testemunha - Taxa Erro: 4,57%




gt02 - Proposto - Taxa Erro: 0,52%



gt02 - Testemunha - Taxa Erro: 1,27%



gt07 - Proposto - Taxa Erro: 0,21%



gt07 - Testemunha - Taxa Erro: 0,64%

Resultados


Resultado de Imagens onde não foi possível a utilização do recurso do polígono de corte pelo Mod. Proposto




gt13 - Proposto - Taxa Erro: 1,08%



gt13 - Testemunha - Taxa Erro: 2,11%



cross - Proposto - Taxa Erro: 0,48%



cross - Testemunha - Taxa Erro: 1,79%



Resultados

Resultado de Imagens: 5 melhores taxas de classificação → Mod. Proposto

Tabela 7.4 – Características das redes geradas a partir das imagens com cinco melhores taxas de erro no método proposto

Nome Imagem	Pixel Original	Pixel Cinza	Método Proposto			Método Testemunha		
			Part.	Vért.	Arestas	Part.	Vért.	Arestas
Monitor_2007_003011	187500	1614	949	1428	114506	5176	16800	2237507
Train_2007_004627	187500	1180	1199	2220	2023323	5276	16800	2213111
Car_2008_001716	143424	3028	2127	4028	373544	4468	12814	1649199
Monitor_2007_004193	187500	800	877	1287	117952	4119	16800	2180800
Person_2007_002639	187500	1507	803	1482	142950	3921	16800	2233489
Média	178685	1626	1191	2089	554455	4592	16003	2102821

Fonte: Elaborado pelo autor

Resultados

Resultado de Imagens:
5 melhores taxas de
classificação → Mod.
Proposto

Tabela 7.5 – Taxa de erro dos modelos a partir dos cinco melhores resultados do método proposto

Nome Imagem	Pixel		Método Proposto			Método Testemunha		
			Px	%	Dv	Px	%	Dv
	Original	Cinza	Erro	Erro	Pad	Erro	Erro	Pad
Monitor_2007_003011	187500	1614	29	0,02%	0,00%	2021	1,09%	0,12%
Train_2007_004627	187500	1180	162	0,09%	0,01%	1409	0,76%	0,02%
Car_2008_001716	143424	3028	143	0,10%	0,01%	3528	2,51%	0,10%
Monitor_2007_004193	187500	800	198	0,11%	0,00%	5601	3,00%	0,28%
Person_2007_002639	187500	1507	215	0,12%	0,00%	4592	2,47%	0,10%
Média	178685	1626	149	0,08%		3430	1,94%	

Fonte: Elaborado pelo autor


Tabela 7.6 – Tempo de execução dos modelos a partir dos cinco melhores resultados do método proposto

Nome Imagem	Pixel	Método Proposto		Método Testemunha	
		Tempo	Desvio	Tempo	Desvio
Monitor_2007_003011	187500	227,00	48,0	777,1	90,34
Train_2007_004627	187500	323,41	79,8	757,83	140,97
Car_2008_001716	143424	273,70	34,1	842,3	97,41
Monitor_2007_004193	187500	199,79	8,84	927,99	161,08
Person_2007_002639	187500	253,41	50,84	811,27	58,1
Média	178684,8	255,46		823,30	


Fonte: Elaborado pelo autor

Resultados

Resultado de Imagens:
5 melhores taxas de
classificação → Mod.
Proposto



monitor_2007_003011 - Proposto - Taxa Erro: 0,02%



monitor_2007_003011 - Testemunha - Taxa Erro: 1,09%



train_2007_004627 - Proposto - Taxa Erro: 0,09%



train_2007_004627 - Testemunha - Taxa Erro: 0,76%



car_2008_001716 - Proposto - Taxa Erro: 0,10%



car_2008_001716 - Testemunha - Taxa Erro: 2,51%

Resultados

Resultado de Imagens:
5 melhores taxas de
classificação → Mod.
Proposto




monitor_2007_004193 - Proposto - Taxa Erro: 0,11%



monitor_2007_004193 - Testemunha - Taxa Erro: 3,00%



person_2007_002639 - Proposto - Taxa Erro: 0,12%



person_2007_002639 - Testemunha - Taxa Erro: 2,47%

Resultados

Resultado de Imagens: 5 melhores taxas de erro Mod. Testemunha

Tabela 7.7 – Características das redes geradas a partir das imagens com cinco melhores taxas de erro no método testemunha

Nome Imagem	Pixel Original	Pixel Cinza	Método Proposto			Método Testemunha		
			Part.	Vért.	Arestas	Part.	Vért.	Arestas
person2	270000	1951	2720	7000	770573	6294	24300	3212419
book	307200	2566	4163	20664	2481056	4731	27648	3605820
aero_2007_000032	140500	2863	1426	2856	297608	4187	12600	1656481
fullmoon	154700	423	906	1680	184919	3038	13860	1516112
Plant_2007_004121	166000	1391	682	952	68462	4547	14850	1982433
Média	207680	1839	1979	6630	760524	4559	18652	2394653

Fonte: Elaborado pelo autor

Resultados

Resultado de
Imagens: 5
melhores
taxas de erro
Mod.
Testemunha

Tabela 7.8 – Taxa de erro dos modelos a partir dos cinco melhores resultados do método testemunha

Nome Imagem	Pixel		Método Proposto			Método Testemunha		
	Original	Cinza	Px Erro	% Erro	Dv Pad	Px Erro	% Erro	Dv Pad
person2	270000	1951	604	0,23%	0,01%	521	0,19%	0,01%
book	307200	2566	857	0,28%	0,02%	990	0,32%	0,02%
aero_2007_000032	140500	2863	190	0,14%	0,01%	449	0,33%	0,05%
fullmoon	154700	423	253	0,16%	0,02%	593	0,38%	0,01%
Plant_2007_004121	166000	1391	192	0,12%	0,00%	768	0,47%	0,18%
Média	207680	1839	419	0,20%		664	0,32%	

Fonte: Elaborado pelo autor

Tabela 7.9 – Tempo de execução dos modelos a partir dos cinco melhores resultados do método testemunha

Nome Imagem	Pixel Original	Método Proposto		Método Testemunha	
		Tempo	Desvio	Tempo	Desvio
person2	270000	588,06	96,62	1387,25	67,8
book	307200	677,41	79,5	1131,46	51,81
aero_2007_000032	140500	226,3	39,14	718,76	79,08
fullmoon	154700	298,05	58,66	1384,66	76,13
Plant_2007_004121	166000	129,94	2,64	1099,84	139,52
Média	207680	383,95		1144,39	

Fonte: Elaborado pelo autor

Resultados


Resultado de
Imagens: 5
melhores
taxas de erro
Mod.
Testemunha





person2 - Proposto - Taxa Erro : 0,23%




person2 - Testemunha - Taxa Erro : 0,19%



book - Proposto - Taxa Erro : 0,28%



book - Testemunha - Taxa Erro : 0,32%



aero_2007_000032 - Proposto - Taxa Erro : 0,14%




aero_2007_000032 - Testemunha - Taxa Erro : 0,33%




Resultados

Resultado de
Imagens: 5
melhores
taxas de erro
Mod.
Testemunha




fullmoon - Proposto - Taxa Erro : 0,16%



fullmoon - Testemunha - Taxa Erro : 0,38%



plant_2007_004121 - Proposto - Taxa Erro : 0,12%



plant_2007_004121 - Testemunha - Taxa Erro : 0,47%



Resultados

Resultado de Imagens: 5 piores taxas de erro Mod. Proposto

Tabela 7.10 – Características das redes geradas a partir das imagens com cinco piores taxas de erro no método proposto

Nome Imagem	Pixel Original	Pixel Cinza	Método Proposto			Método Testemunha		
			Part.	Vért.	Arestas	Part.	Vért.	Arestas
teddy	113032	0	1335	4674	556958	2351	10115	1261233
189080	154401	0	3630	10640	1194831	4274	13824	1767638
208001	154401	0	2344	5632	611561	4549	13824	1786864
69020	154401	2211	6524	12576	1418336	7091	13824	1864183
376043	154401	0	2453	7104	767971	3254	13824	1859124
Média	146127	442	3257	8125	909931	4304	13082	1707808

Fonte: Elaborado pelo autor

Resultados

Resultado de
Imagens: 5
piores taxas
de erro Mod.
Proposto

Tabela 7.11 – Taxa de erro dos modelos a partir dos cinco piores resultados do método proposto

Nome Imagem	Pixel		Método Proposto			Método Testemunha		
			Px	%	Dv	Px	%	Dv
	Original	Cinza	Erro	Erro	Pad	Erro	Erro	Pad
teddy	113032	0	1383	1,22%	0,00%	2600	2,30%	0,12%
189080	154401	0	1994	1,29%	0,15%	2693	1,74%	0,18%
208001	154401	0	1999	1,29%	0,04%	2179	1,41%	0,09%
69020	154401	2211	2240	1,47%	0,02%	3055	2,01%	0,06%
376043	154401	0	3244	2,10%	0,09%	7125	4,61%	0,36%
Média	146127	442	2172	1,49%		3530	2,42%	

Fonte: Elaborado pelo autor

Tabela 7.12 – Tempo de execução dos modelos a partir dos cinco piores resultados do método proposto

Nome Imagem	Pixel	Método Proposto		Método Testemunha	
		Tempo	Desvio	Tempo	Desvio
teddy	113032	571,4	124,79	583,3	74,55
189080	154401	537,23	157,8	838,11	169,39
208001	154401	407,56	132	756,87	65,5
69020	154401	472,67	18,87	1160,63	133,45
376043	154401	647,5	139,18	1068,84	112,95
Média	146127,2	527,27		881,55	

Fonte: Elaborado pelo autor

Resultados



teddy - Proposto - Taxa Erro: 1,22%



teddy - Testemunha - Taxa Erro: 2,30%



189080 - Proposto - Taxa Erro: 1,29%



189080 - Testemunha - Taxa Erro: 1,74%



208001 - Proposto - Taxa Erro: 1,29%



208001 - Testemunha - Taxa Erro: 1,41%



69020 - Proposto - Taxa Erro: 1,47%



69030 - Testemunha - Taxa Erro: 2,01%



386043 - Proposto - Taxa Erro: 2,10%



376043 - Testemunha - Taxa Erro: 4,61%

Resultado de Imagens: 5 piores taxas de erro Mod. Proposto

Resultados

Piores Tempos
de
Processamento
– Mod. Proposto

Tabela 7.14 – Características das redes geradas a partir da imagens com pior tempo de processamento pelo método proposto

Nome Imagem	Pixel Original	Pixel Corte	Pixel Cinza	Método Proposto			Método Testemunha		
				Part.	Vért.	Arestas	Part.	Vert.	Arestas
gt07	494400	494400	6656	7598	44400	5247685	7598	44400	5721712
gt13	476000	476000	12429	5314	42720	5149011	5314	42720	5536232
cross	270000	270000	1870	4206	24300	2883050	4206	24300	3148781
gt02	419200	419200	2229	6294	37680	4371763	6294	37680	4772882
banana1	307200	236925	2562	3987	21175	2434701	4812	27648	3547442

Fonte: Elaborado pelo autor

Tabela 7.15 – Características das redes geradas a partir da imagens com pior tempo de processamento pelo método proposto

Nome Imagem	Pixel Original	Pixel Corte	Método Proposto		Método Testemunha	
			Tempo	Desvio	Tempo	Desvio
gt07	494400	494400	1567,95	20,95	1637,93	109,4
gt13	476000	476000	1505,62	90,38	1767,62	337,78
cross	270000	270000	1238,05	238,78	1123,14	67,23
gt02	419200	419200	1098,05	38,84	1146,92	68,42
banana1	307200	236925	953,00	182,00	1248,77	60,78
Média	393360		1272,53		1384,88	

Fonte: Elaborado pelo autor

Resultados

Resultado do processamento da base completa


Tabela 7.13 – Resultado da execução dos Métodos Proposto e Testemunha na Base Estudada

Método	Pixel Original	Pixel Cinza	Características			Taxa de Erro		
			Part.	Vért.	Arestas	Px.Err.	%Erro	Tempo
Proposto	200124	2783	2860	7538	838564	963	0,49%	432,54
Testemunha	200124	2783	5487	17946	2354555	5856	3,14%	1082,94

Fonte: Elaborado pelo autor

Resultados

Relação Taxa de Erro e Tempo (segundos) – Mod. Proposto e Testemunha



Conclusão

- Melhora na automação do processo com eliminação dos ajustes no vetor de pesos;
- Com a metodologia proposta obteve-se resultados satisfatórios com uma taxa de erro na classificação de 0,49%
- Maior estabilidade do modelo proposto frente as diferentes imagens apresentadas

Obrigado

Referências Bibliográficas

- ALPAYDIN, E. *Introduction to Machine Learning*. 3. ed. Cambridge, MA: MIT Press, 2014. (Adaptive Computation and Machine Learning).
- ARAUJO, A. F. Método para extração e caracterização de lesões de pele usando difusão anisotrópica, crescimento de regiões, watershed e contornos ativos. Universidade Estadual Paulista, São José do Rio Preto, SP -Brasil, 2010.
- BOCCALETTI, S. et al. Complex networks : Structure and dynamics. *Phys. Rep.*, v. 424, n. 4-5, p. 175–308, Fervier 2006.
- BREVE, F. et al. Particle competition and cooperation in networks for semi-supervised learning. *Knowledge and Data Engineering*, IEEE Transactions, n. 24(9), p. 1686–1698, 2012.
- BREVE, F. A. *Aprendizado de máquina utilizando dinâmica espaço temporal em redes complexas*. São Carlos: USP, 2010.
- BREVE, F. A. Active semi-supervised learning using particle competition and cooperation in networks. *Neural Networks (IJCNN)*, The 2012 International Joint Conference, 2013.
- BREVE, F. A. Auto feature weight for interactive image segmentation using particle competition and cooperation. In: *Proceedings - XI Workshop de Visão Computacional WVC2015*. [S.l.]: XI Workshop de Visão Computacional (WVC2015), 2015. p. 164 – 169.

Referências Bibliográficas

BREVE, F. A.; QUILES, M. G.; ZHAO, L. Interactive image segmentation of non-contiguous classes using particle competition and cooperation. In: *15th International Conference on Computational Science and Its Applications, ICCSA 2015, 2015, Computational Science and Its Applications - ICCSA 2015 - 15th International Conference, Proceedings, Part I*. [S.l.]: Springer International Publishing, 2015. v. 9155, p. 203 – 216.

CHAPELLE, O.; SCHÖLKOPF, B.; ZIEN, A. *Semi-Supervised Learning*. Cambridge, MA, USA: MIT Press, 2006. 508 p. (Adaptive computation and machine learning).

GONZALEZ, R. C.; WOODS, R. E. *Processamento Digital de Imagens*. 3. ed. [S.l.]: Longman do Brasil., 2010. ISBN 9788576054016.

HOPCROFT, J. et al. Natural communities in large linked networks. In: *KDD '03: Proceedings of the ninth ACM SIGKDD international conference on Knowledge discovery and data mining*. New York, NY, USA: ACM, 2003. p. 541–546. ISBN 1-58113-737-0.

LU, T. T. *Fundamental limitations of semi-supervised learning*. Waterloo, Ontario, Canada: [s.n.], 2009.

MA, W.-Y.; MANJUNATH, B. Edgeflow: A technique for boundary detection and image segmentation. *Image Processing, IEEE Transactions*, n. 9(8), p. 1375–1388, 2000.

Referências Bibliográficas

MALMBERG, F. *Graph-based Methods for Interactive Image Segmentation*. [S.l.]: Uppsala University, Centre for Image Analysis, Computerized Image Analysis and Human Computer Interaction, 2011.

NAVON, E.; MILLER, O.; AVERBUCH, A. Color image segmentation based on adaptive local thresholds. *Image and Vision Computing*, v. 23, n. 1, p. 69 – 85, 2005. ISSN 0262-8856.

NEWMAN, M. The structure and function of complex networks. *SIAM review*, JSTOR, v. 45, n. 2, p. 167–256, 2003. ISSN 0036-1445.

NEWMAN, M. E. J. *Networks: An Introduction*. New York: Oxford, 2010.

QUILES, M. G. et al. Particle competition for complex network community detection. *Chaos*, v. 18, n. 3, 2008.

SILVA, T. C.; ZHAO, L. *Machine Learning in Complex Networks*. [S.l.]: Springer International Publishing, 2016.

VAPNIK, V. N. *Statistical Learning Theory*. [S.l.]: Wiley-Interscience, 1998.